

COVID - 19

Image

Segmentation

PRESENTADO POR "AI PA 🤝"



COVID-19

- La pandemia de COVID-19, causada por el virus SARS-CoV-2, comenzó a finales de 2019 y rápidamente se extendió por todo el mundo, convirtiéndose en una emergencia de salud global.
- El COVID-19 es principalmente una enfermedad respiratoria que afecta los pulmones y las vías respiratorias.
- La infección puede variar desde síntomas leves hasta complicaciones graves como neumonía, síndrome de dificultad respiratoria aguda (SDRA), y fallo respiratorio que requiere ventilación mecánica.



Importancia

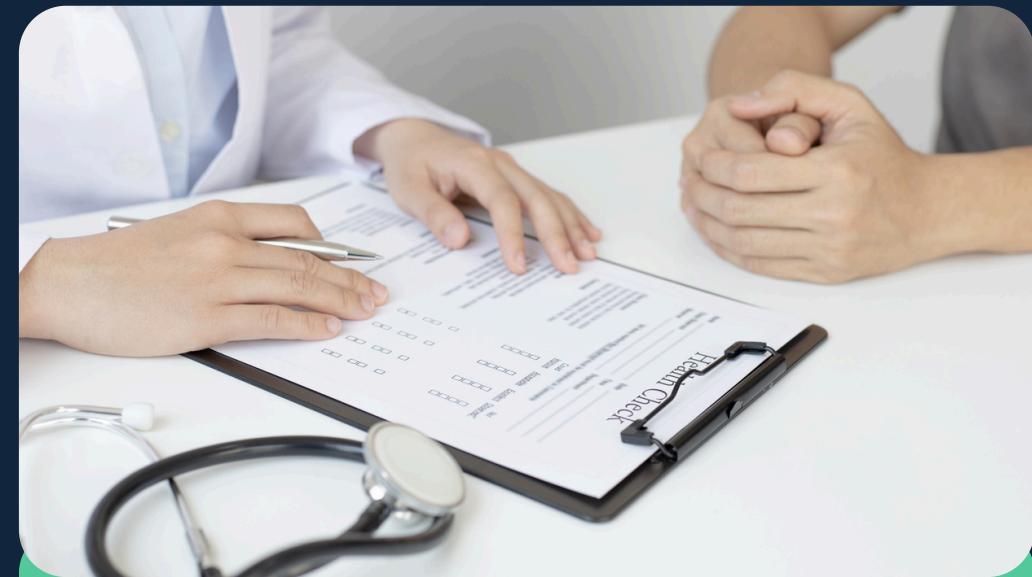
¿Por qué nos interesa como profesionales en AI y ML?



**Desafío
Tecnológico**



**Relevancia e
Impacto**



**Compromiso
Profesional**



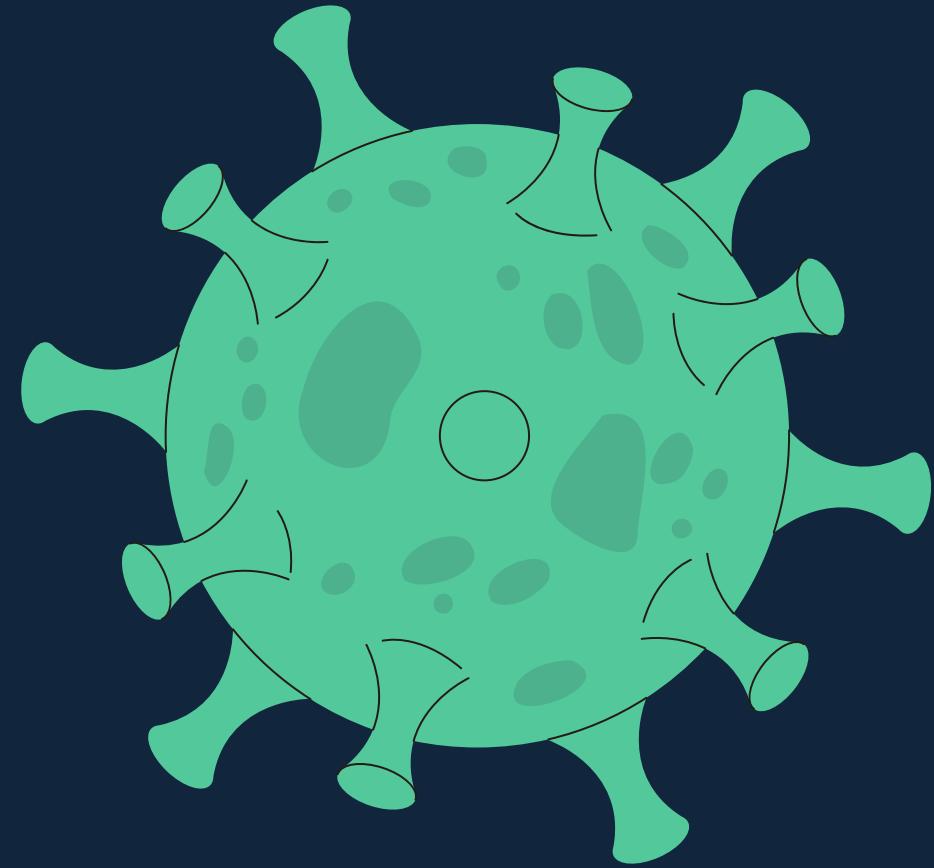
Rol como Data Scientists

Modelo de Machine Learning

Nuestra aportación es el desarrollo de un Modelo de ML que permite el procesamiento de imágenes y clasifica imágenes de pacientes para determinar daño causado por el COVID-19 en los pulmones.

Entender, Presentar e Interpretar Resultados

NO SOMOS MÉDICOS EXPERTOS, pero si data scientists. Podemos ofrecer la interpretación matemática y estadística de los resultados obtenidos.



Red Neuronal Segmentación de imágenes



Pasos de Nuestra Implementación

1. Manejo de datos
2. Construcción y entrenamiento del modelo
3. Análisis de los resultados

Medseg part

Se trata de un conjunto de datos de 100 imágenes de TC axial de más de 40 pacientes con COVID-19 que se convirtieron a partir de imágenes JPG

- images_medseg
 - Imágenes de entrenamiento – 100 cortes de tamaño 512x512
- masks_medseg
 - Máscaras de entrenamiento – 100 máscaras4 canales:
 - 0 - "vidrio esmerilado"
 - 1 - "consolidaciones"
 - 2 - "pulmones otros"
 - 3 - "fondo"

✓ Radiopedia part

Son 9 tomografías computarizadas volumétricas axiales segmentadas de Radiopaedia . Este conjunto de datos incluye volúmenes completos y, por lo tanto, incluye cortes positivos y negativos (373 de un total de 829 cortes han sido evaluados por un radiólogo como positivos y segmentados).

- images_radiopedia
 - imágenes de entrenamiento – 829 cortes de tamaño 512x512
- masks_radiopedia
 - máscaras de entrenamiento – 829 máscaras con 4 canales:
 - 0 - "vidrio esmerilado"
 - 1 - "consolidaciones"
 - 2 - "pulmones otros"
 - 3 - "fondo"

Manejo de Datos

Cargar y convertir imágenes y máscaras de segmentación asegura que los datos estén en el formato adecuado.

Visualizar estos datos permite evaluar su calidad y las predicciones del modelo.

Normalizar las imágenes mantiene consistencia en los valores, ayudando a una mejor convergencia durante el entrenamiento.

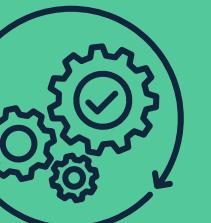
Además, usar técnicas de aumento de datos mejora la capacidad del modelo para generalizar y manejar variaciones, aumentando su robustez.



Preparación



Visualización



Preprocesamiento



Aumento de datos

Manejo de Datos

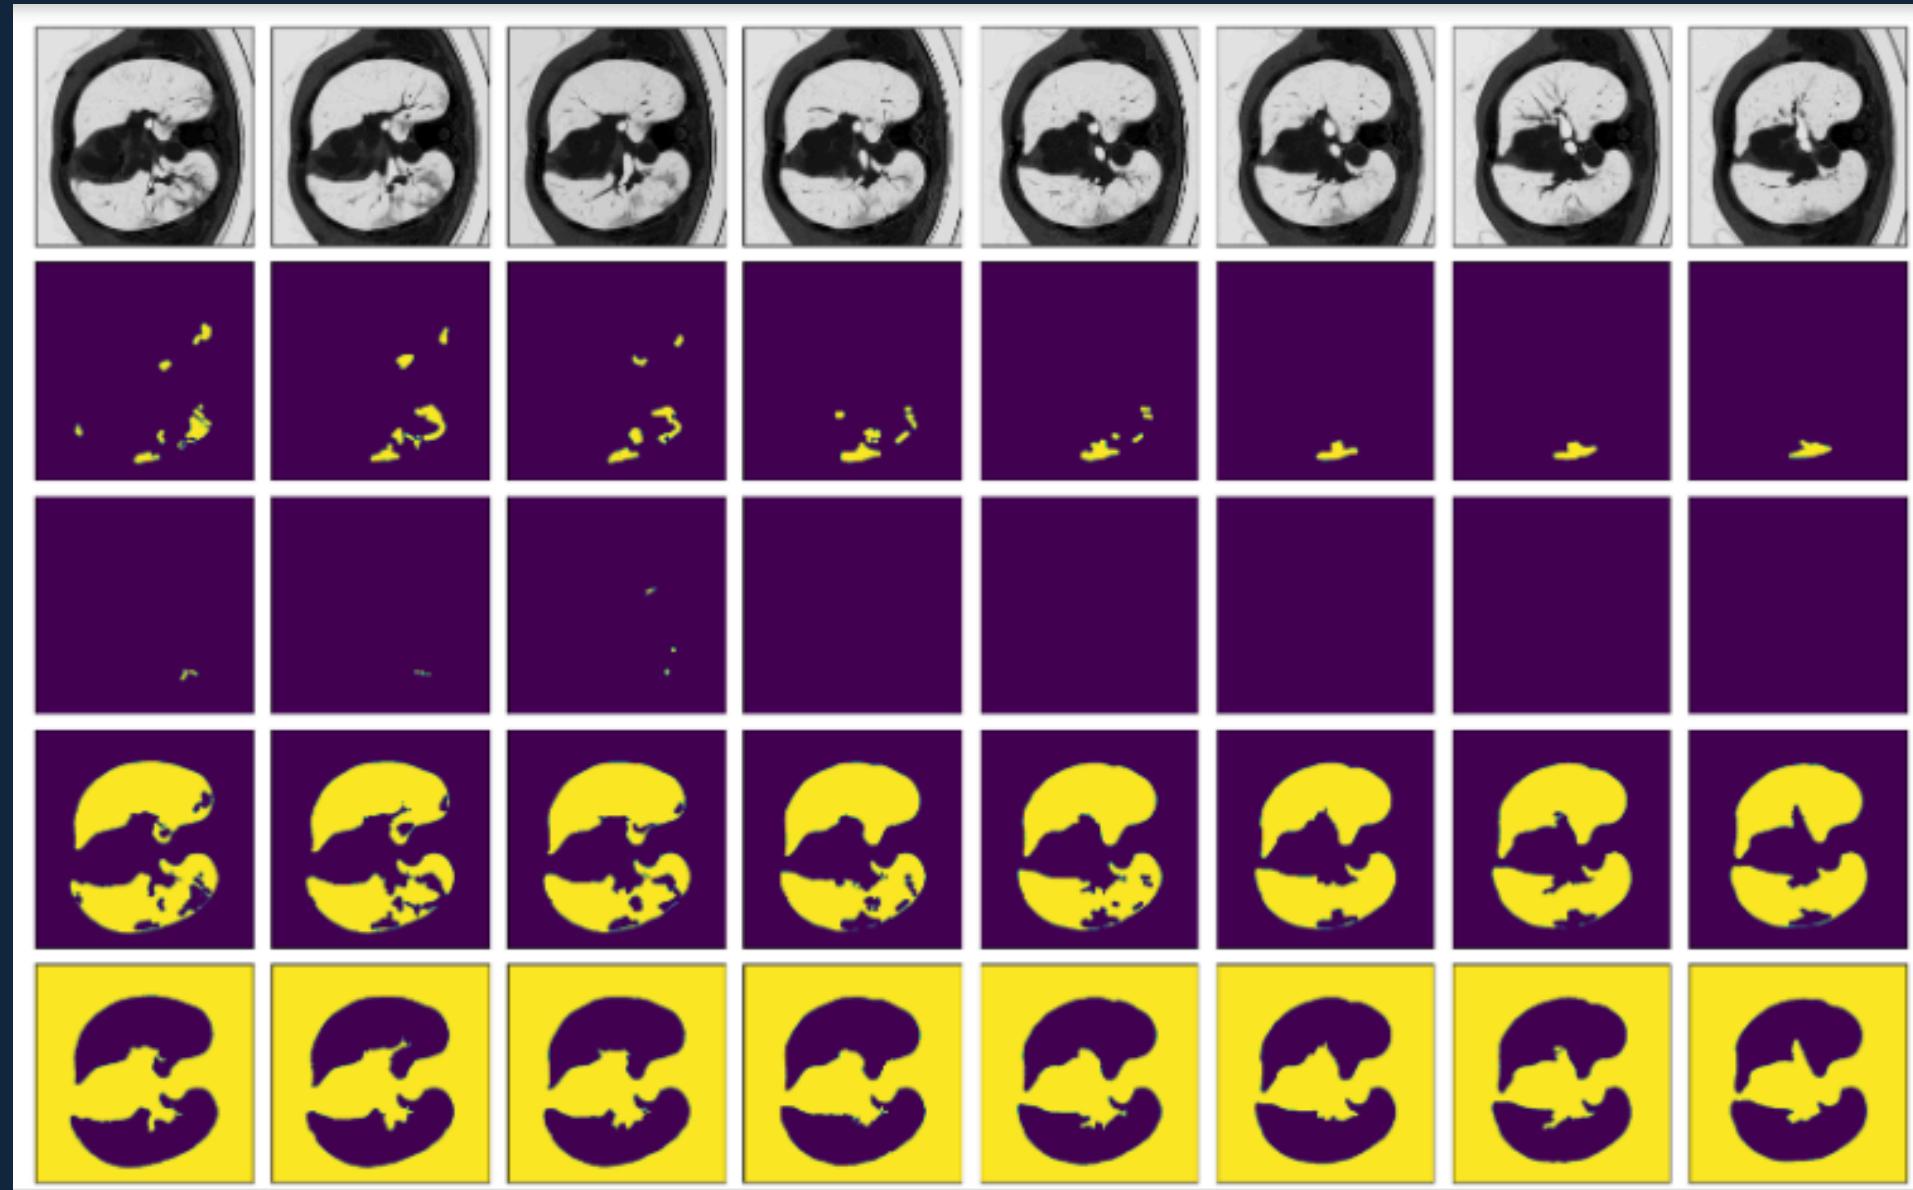
Visualización de Img y 4 clases

Shape

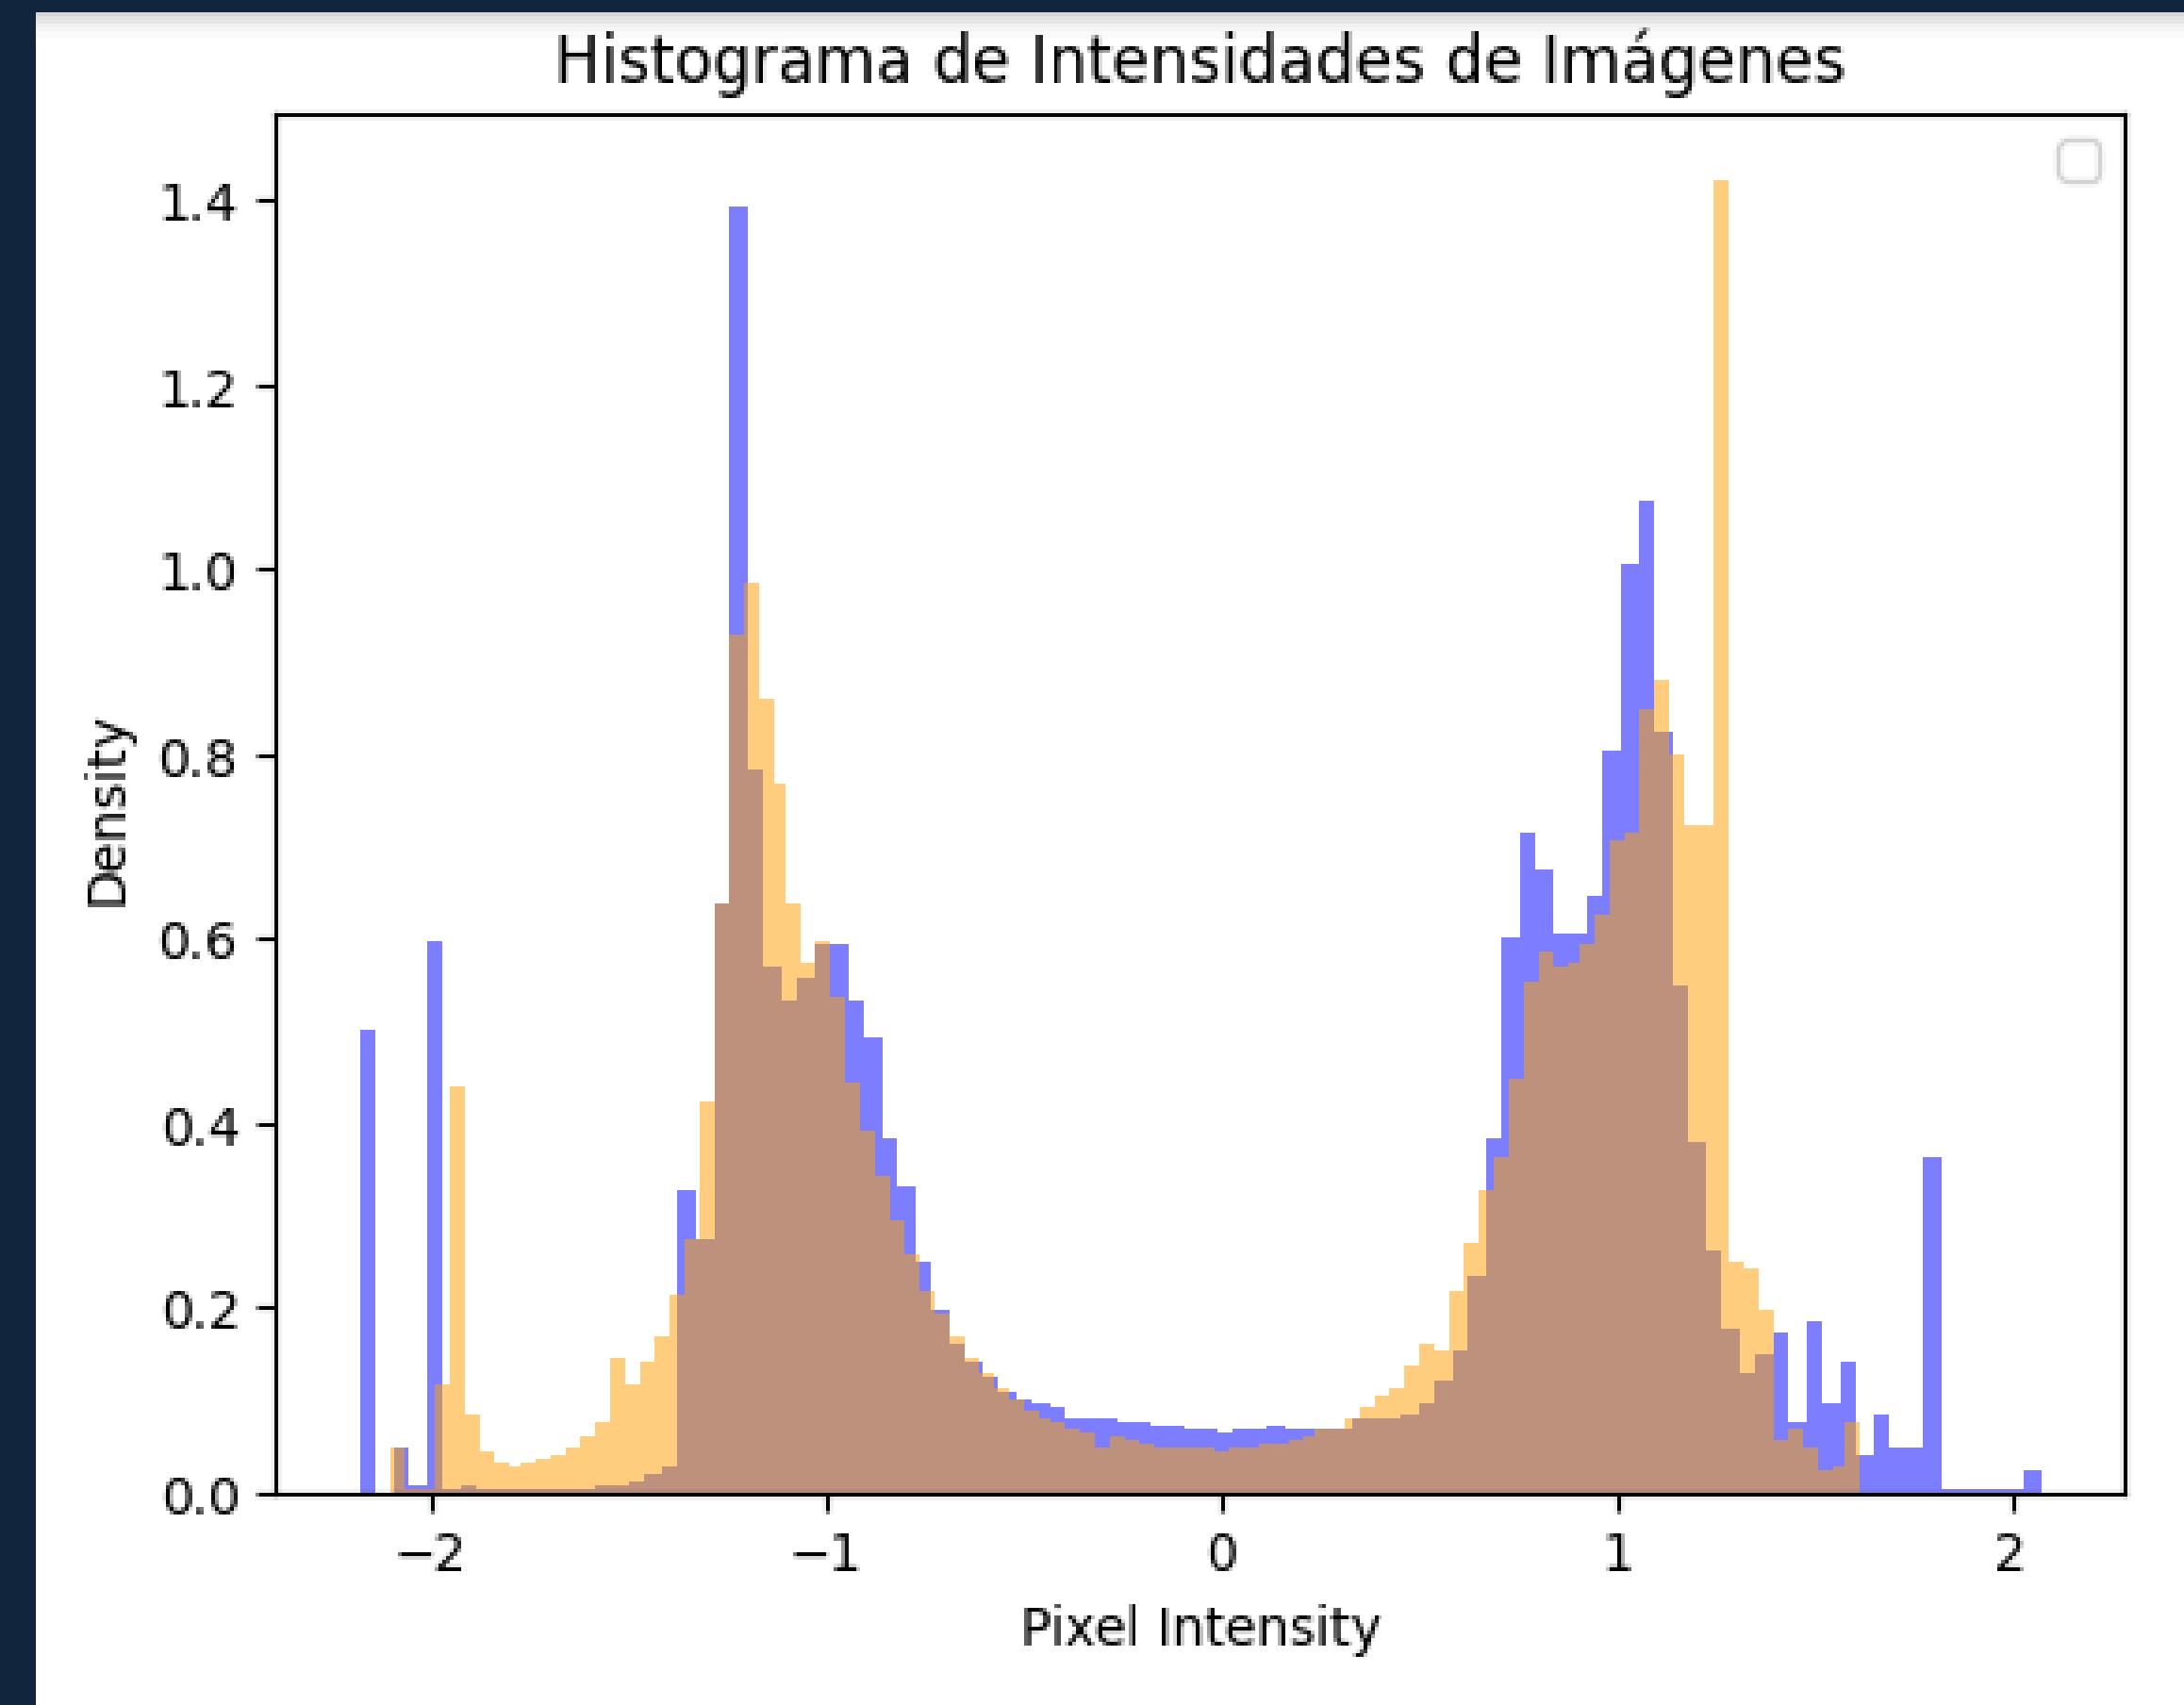
```
Img Radiopedia (829, 512, 512, 1)
Masks Radiopedia (829, 512, 512, 4)
Img Med (100, 512, 512, 1)
Masks Med (100, 512, 512, 4)
```

Normalización

```
mean -451.6488342285156, std 458.5679016113281
mean -451.6488342285156, std 458.5679016113281
mean -451.6488342285156, std 458.5679016113281
```



Manejo de Datos



Construcción y entrenamiento

Seleccionar el tipo de modelo más adecuado para abordar de manera efectiva la problemática que estamos tratando de resolver.

Elegir los hiperparámetros más apropiados, teniendo en cuenta la implementación específica y los resultados que deseamos lograr con el modelo.

Realizar ajustes en los hiperparámetros con el objetivo de alcanzar el rendimiento óptimo de nuestro modelo de red neuronal.



Tipo de Modelo

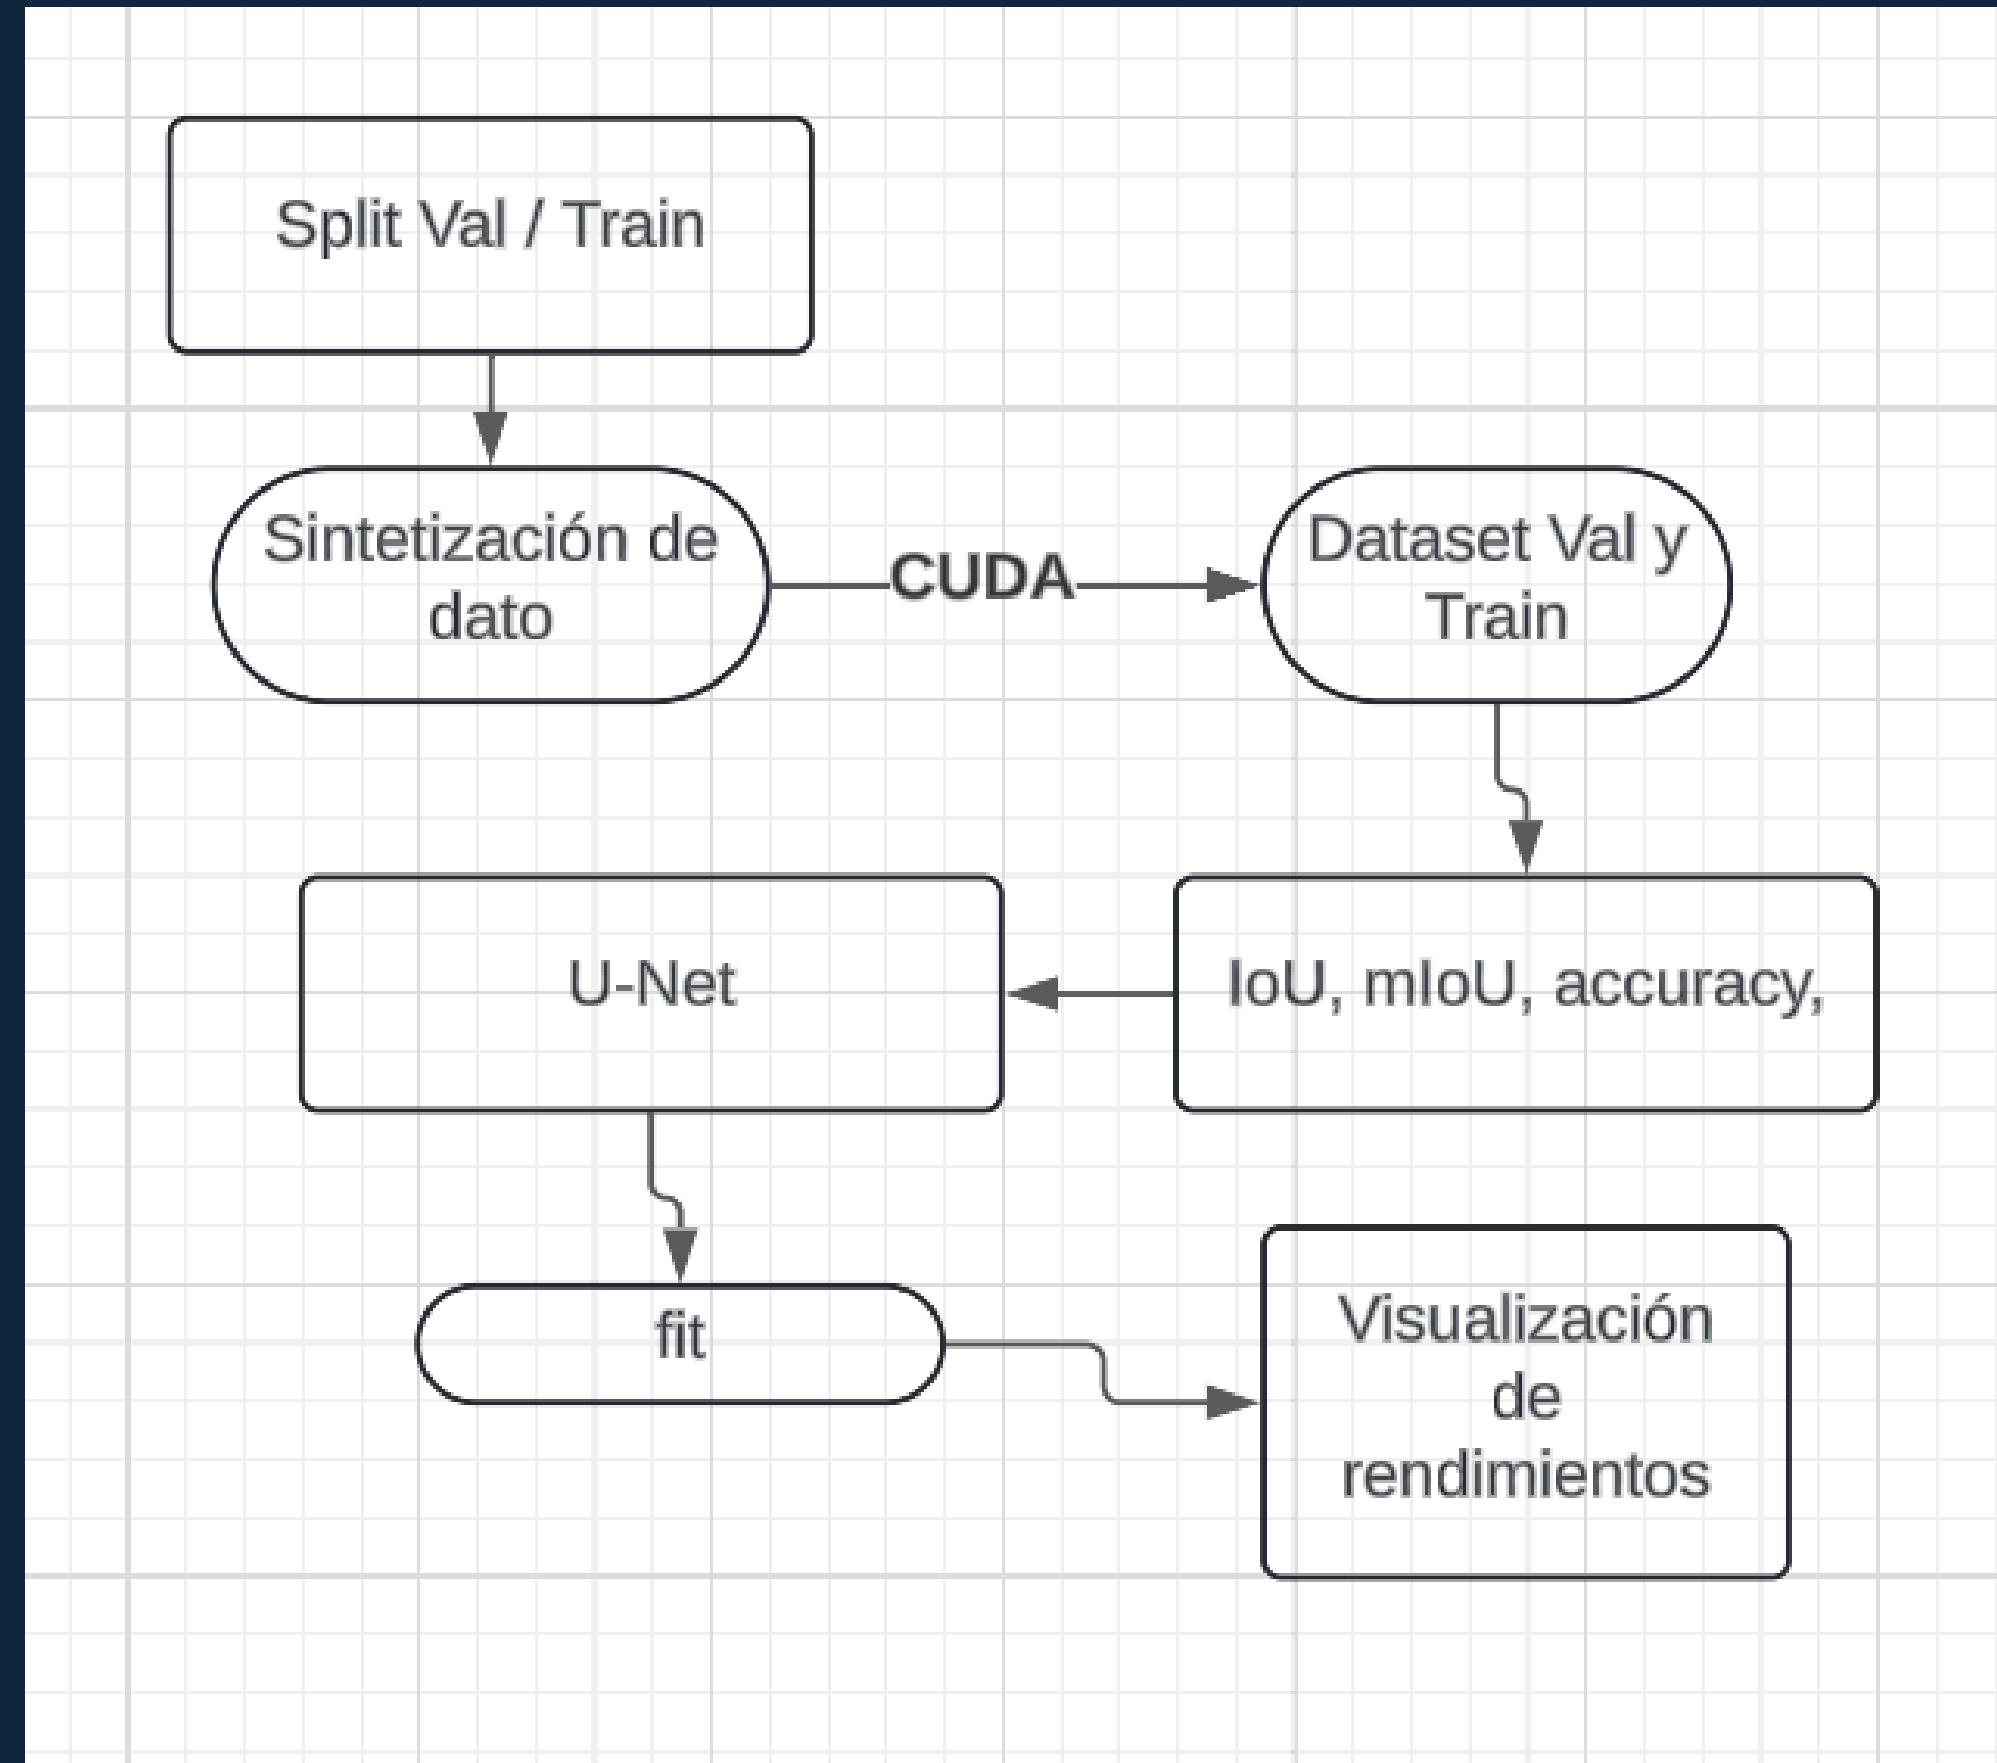


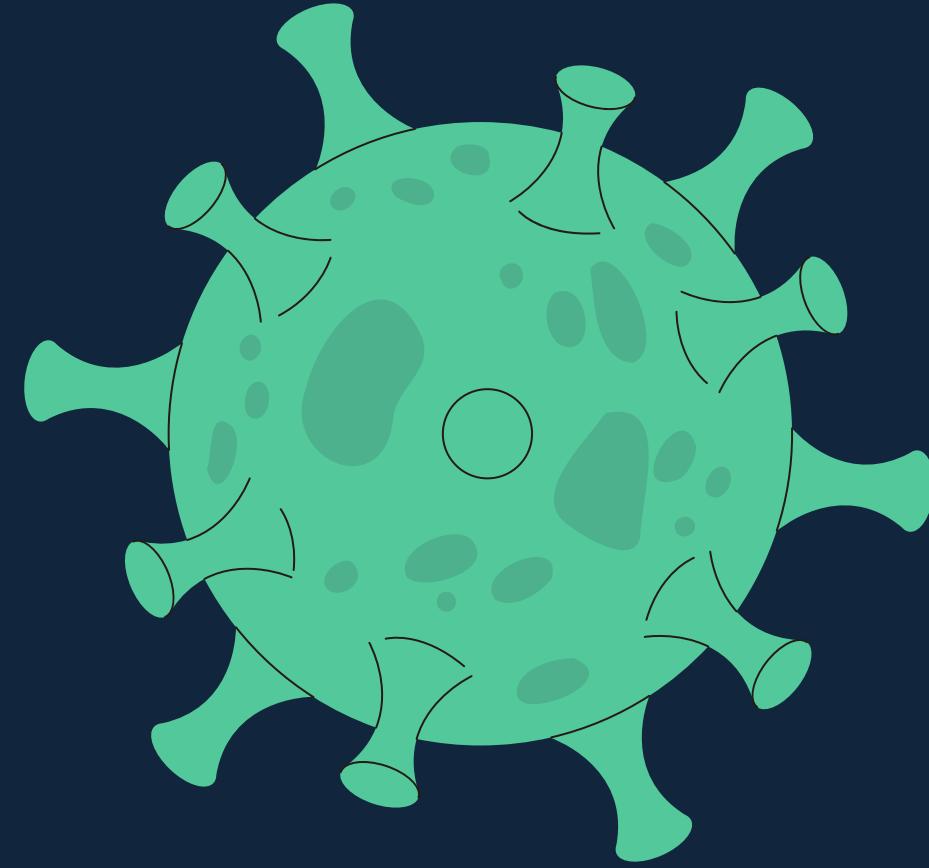
Selección de Hiperparámetros



Ajustes de Hiperparámetros

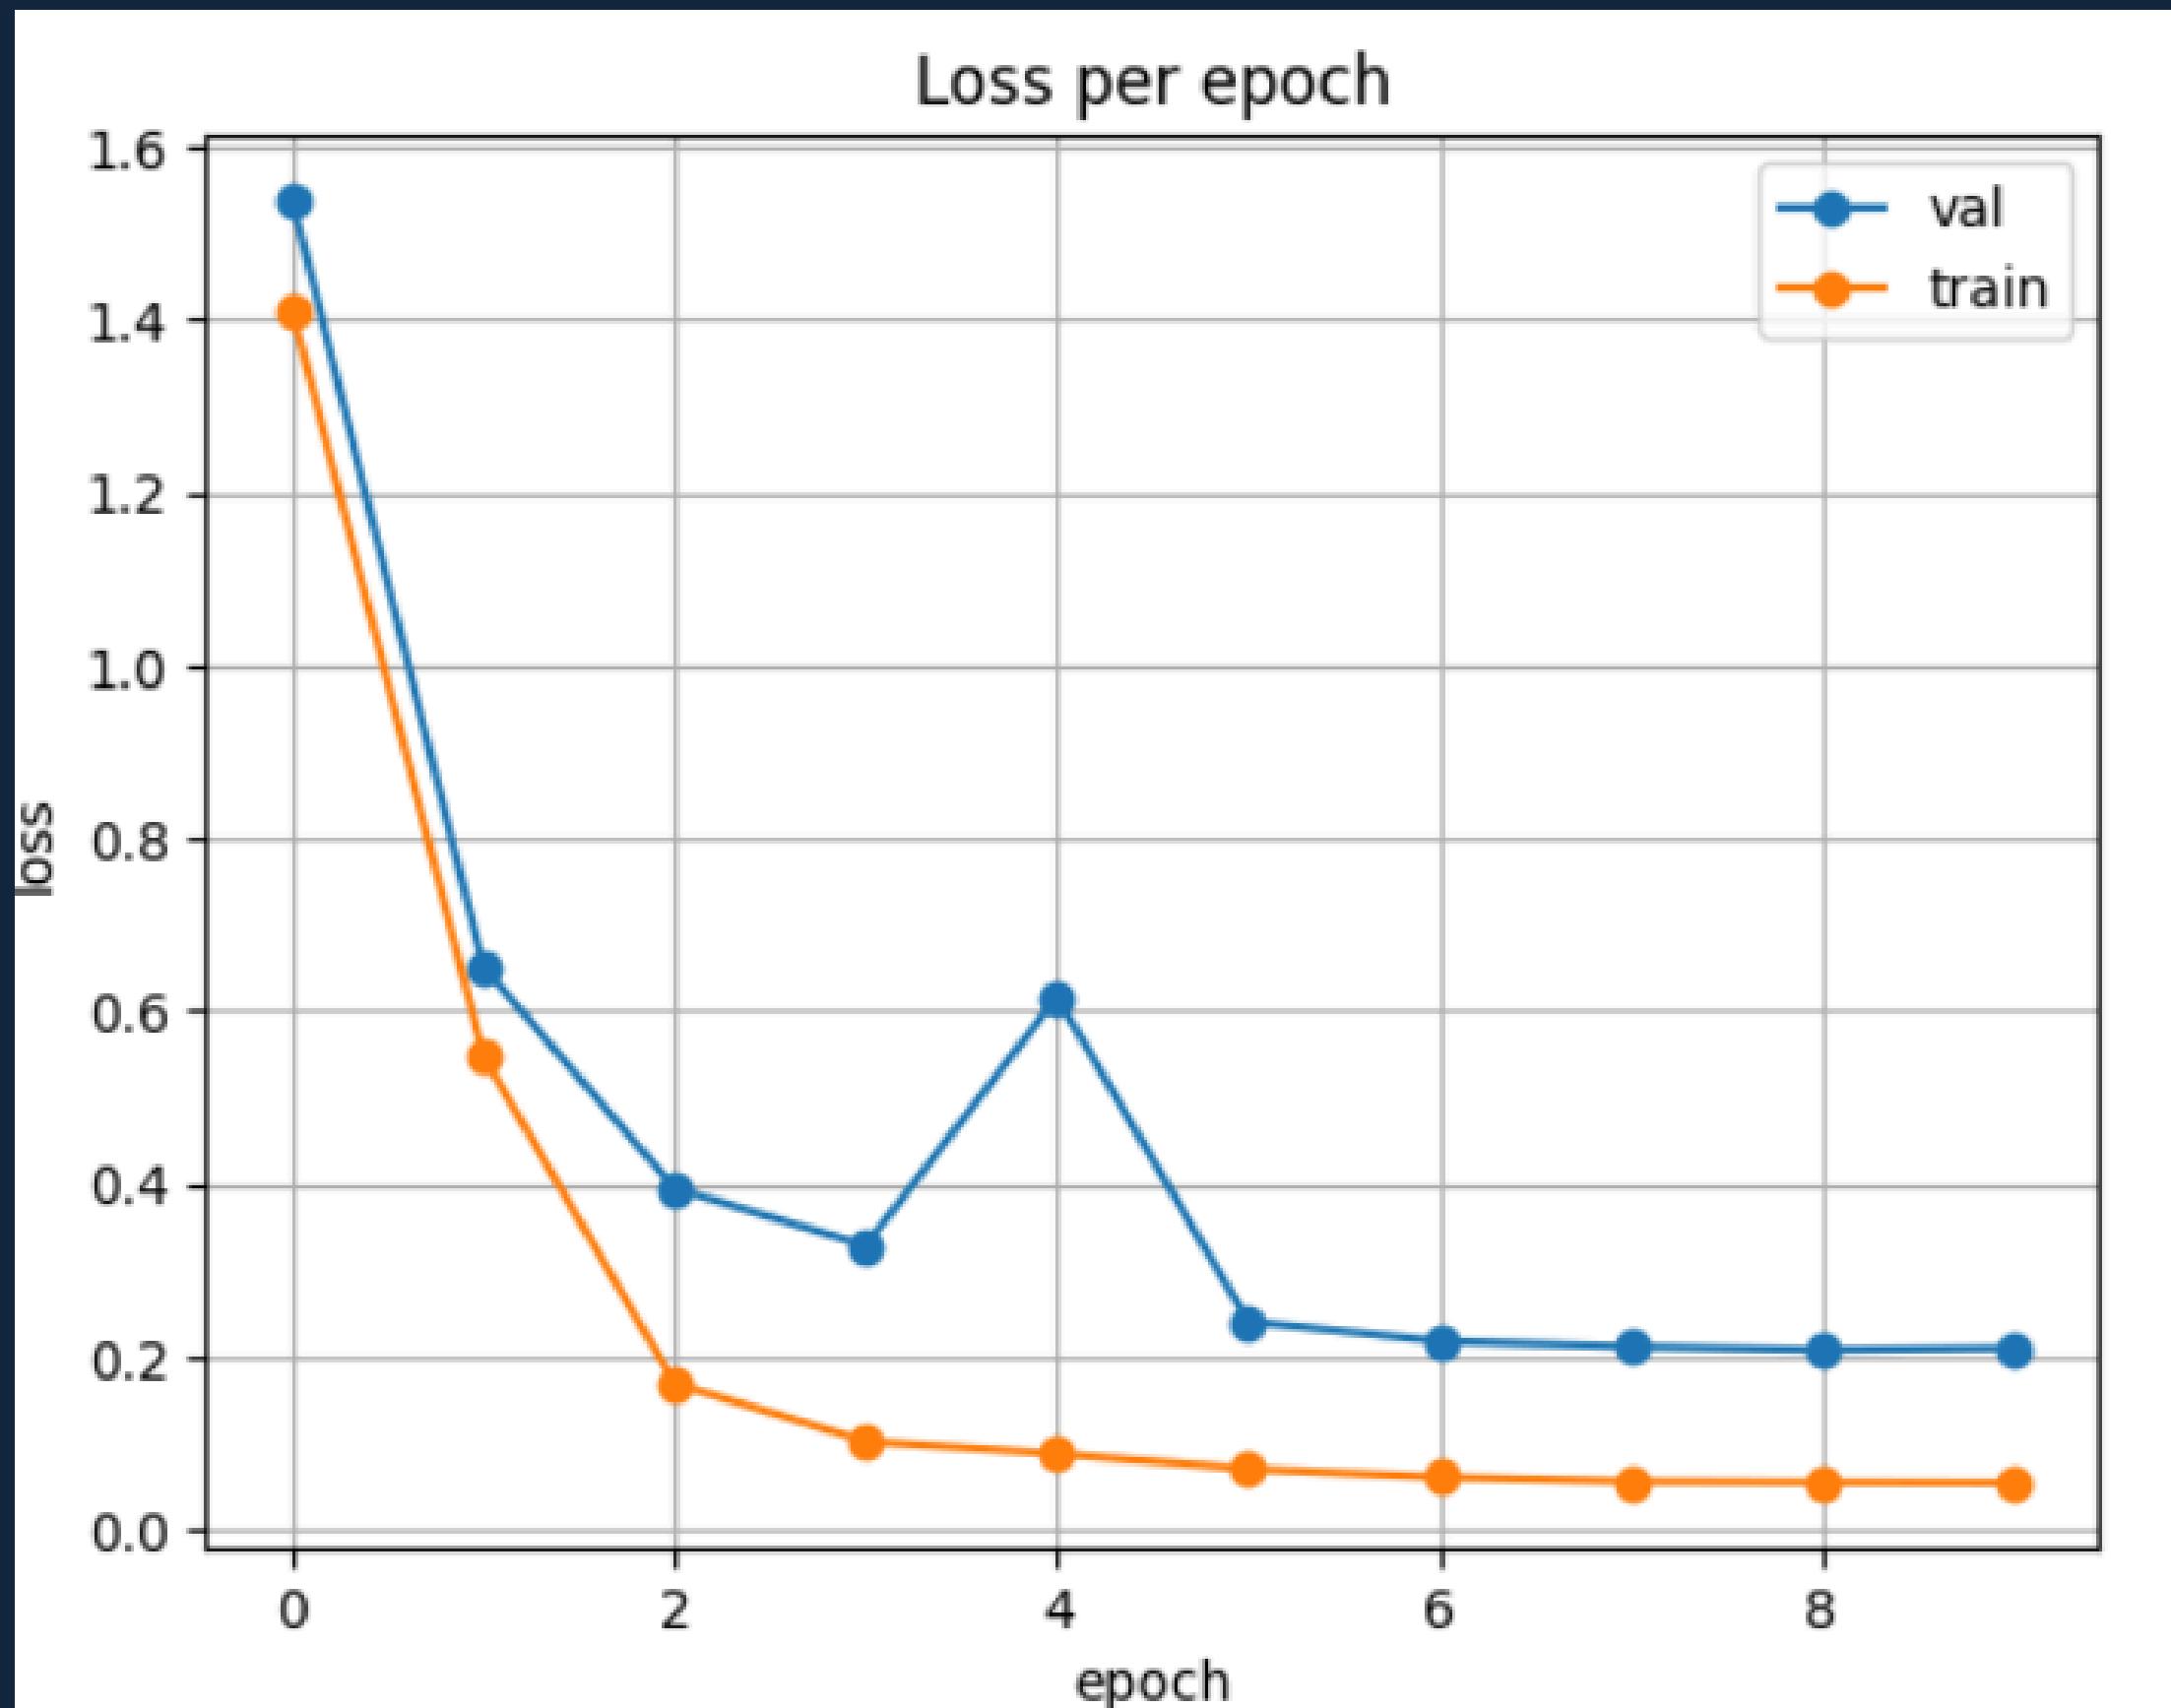
Construcción y entrenamiento





Implementación de nuestra solución

Visualización de rendimientos



LR → 0.001

Epoch → 10

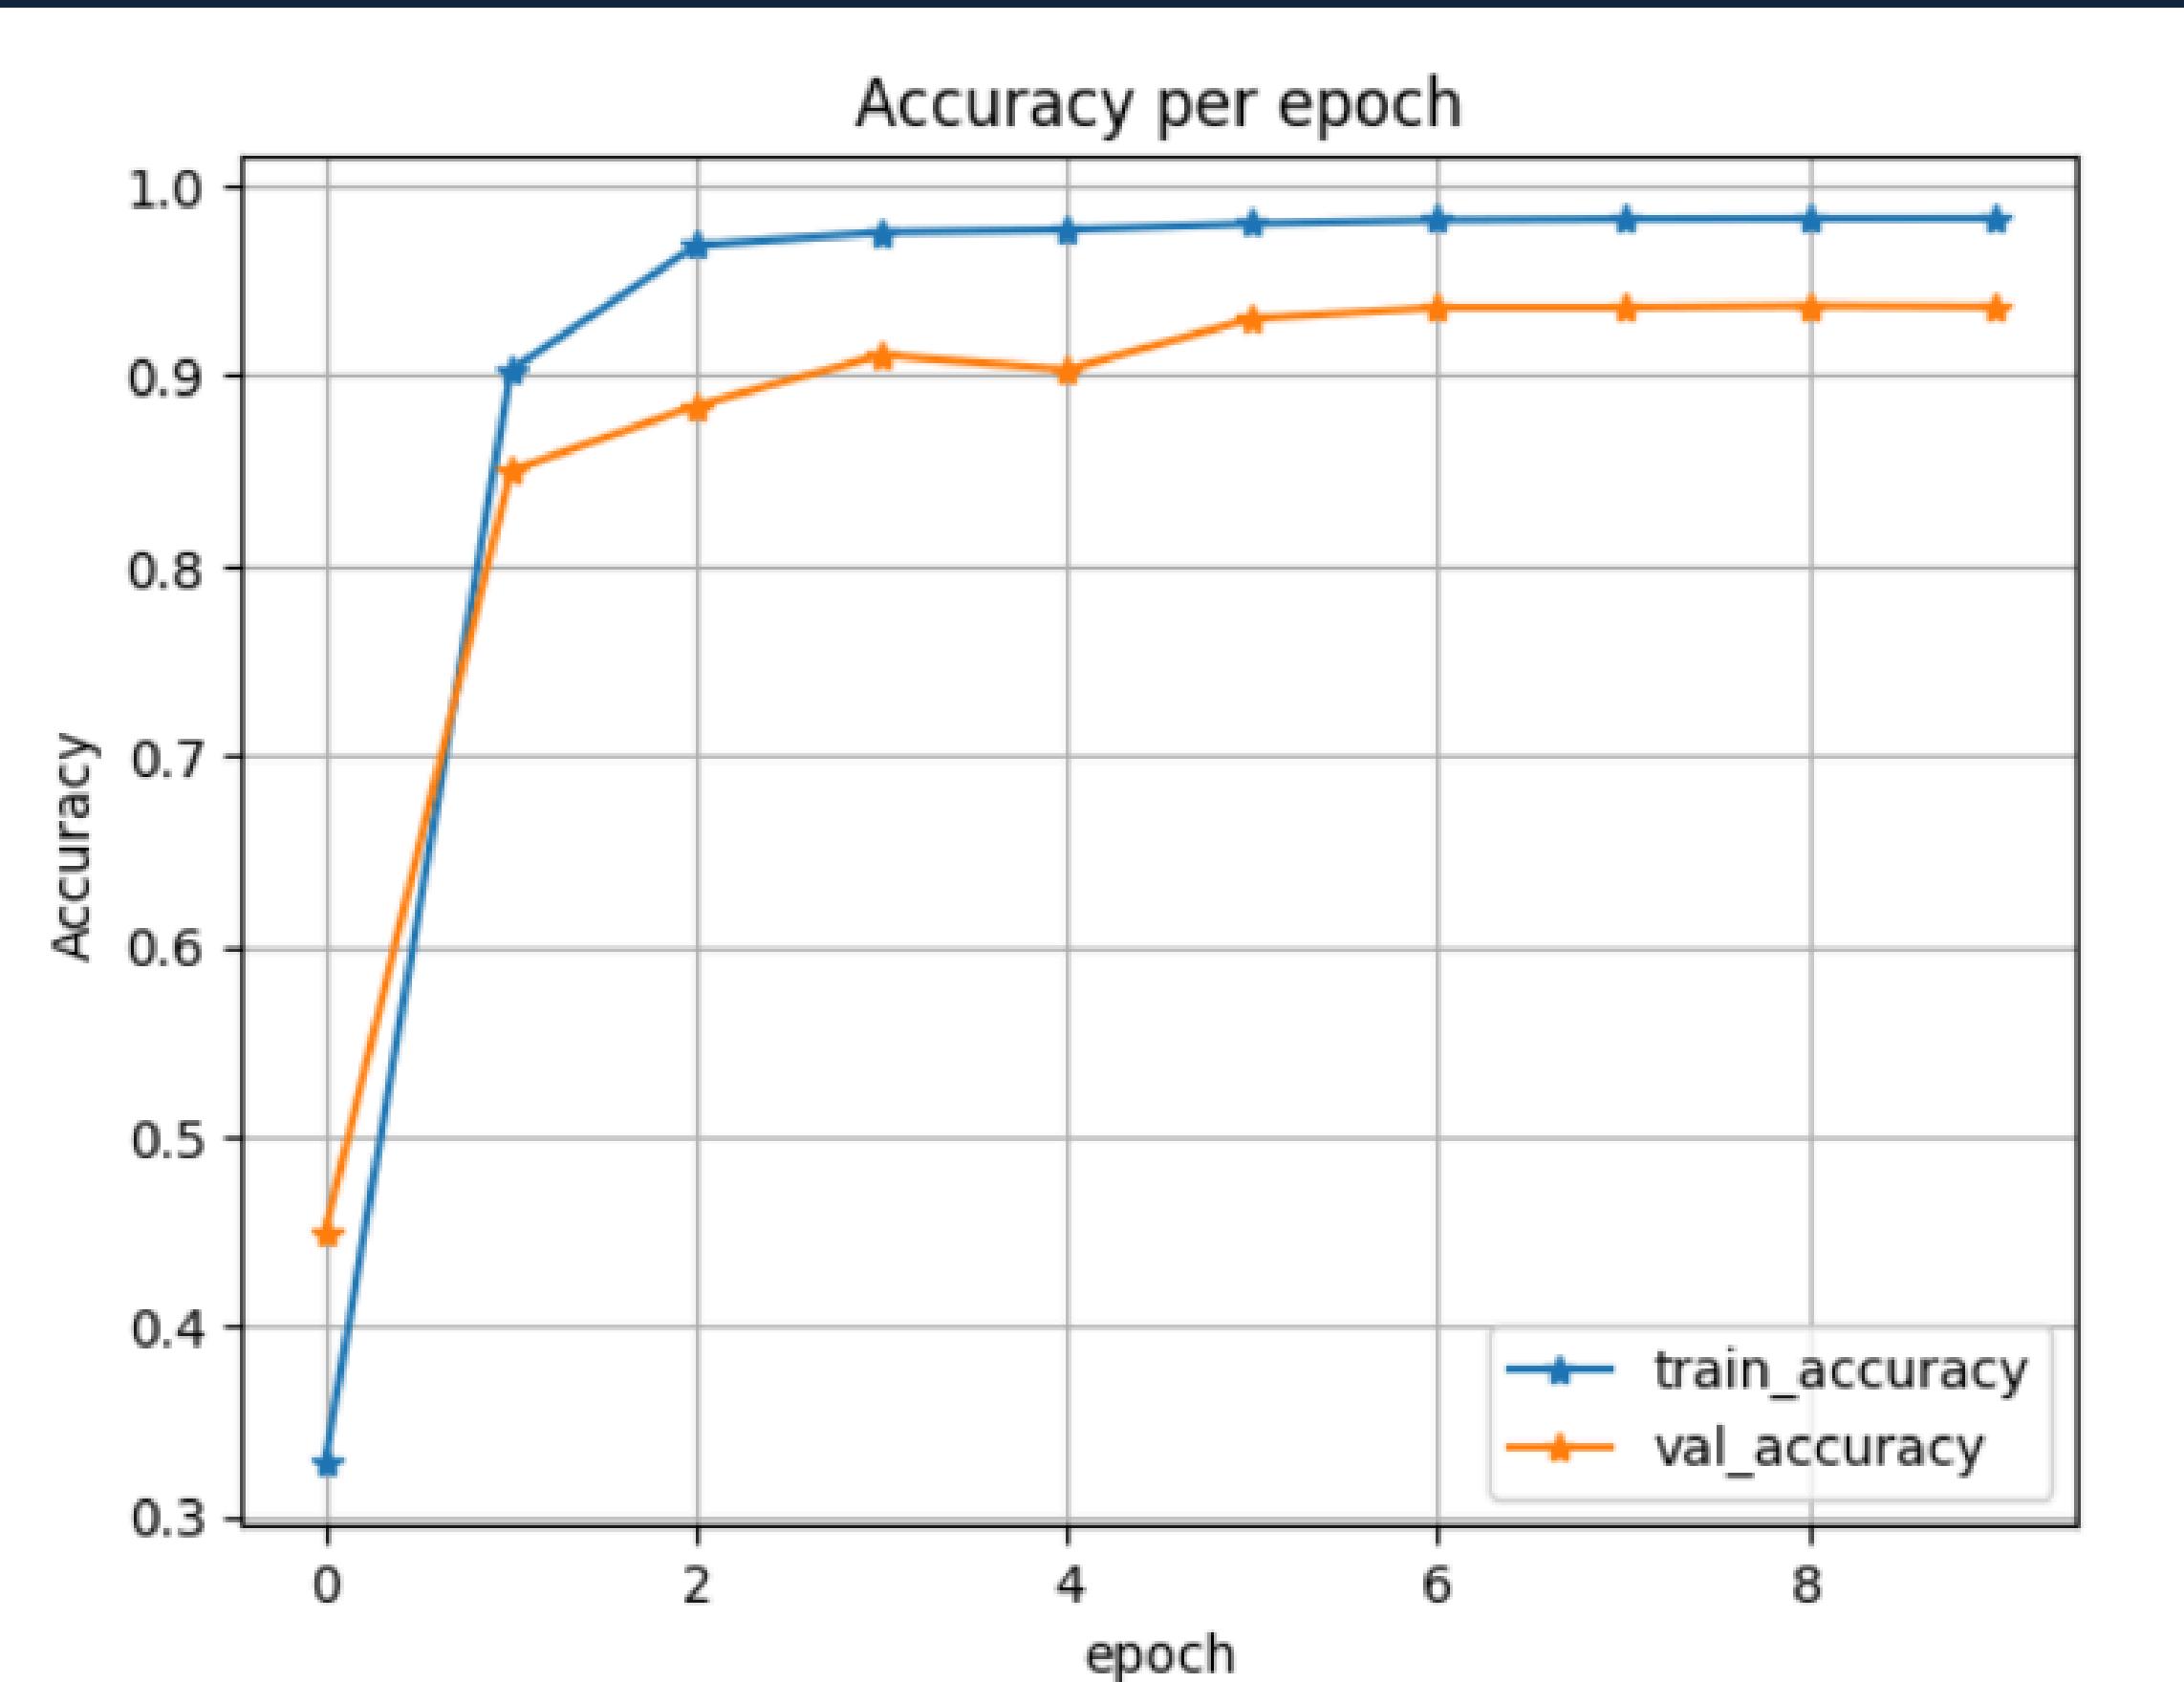
L2 → 0.0001

CrossEntropyLoss ()

Adamw

OneCycleLR

Visualización de rendimientos



LR → 0.001

Epoch → 10

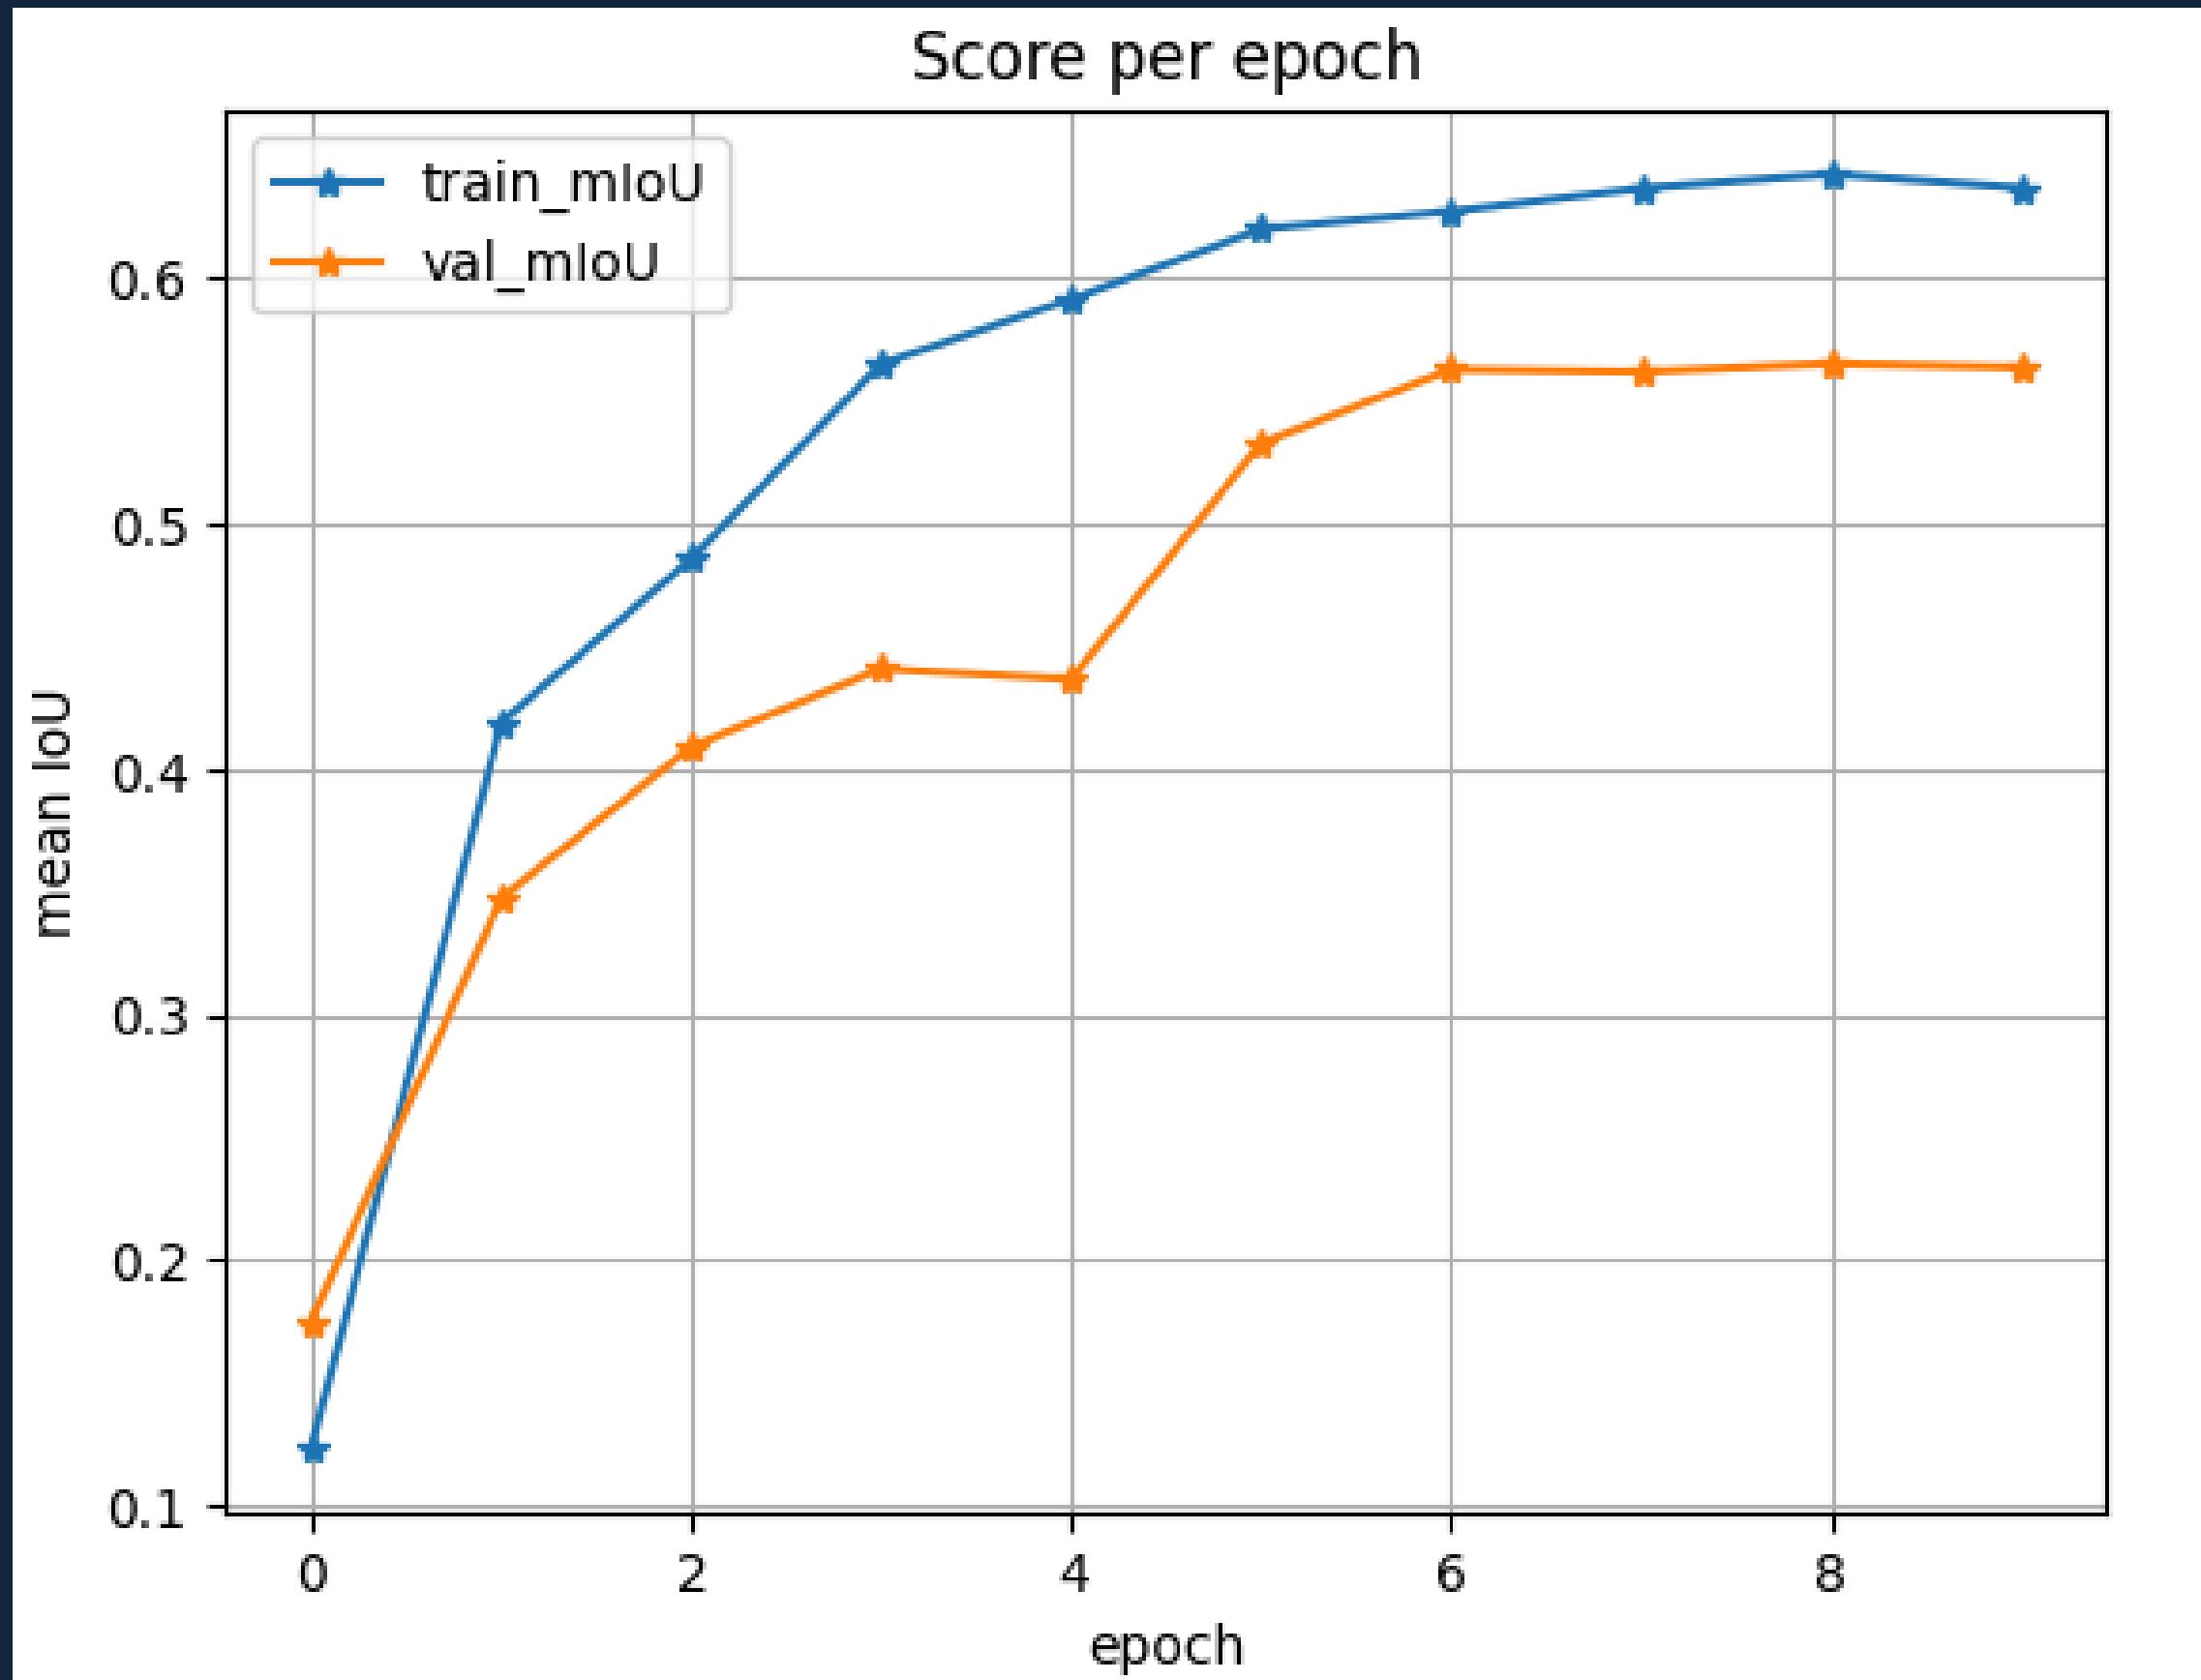
L2 → 0.0001

CrossEntropyLoss ()

Adamw

OneCycleLR

Visualización de rendimientos



LR → 0.001
Epoch → 10
L2 → 0.0001
CrossEntropyLoss ()
Adamw
OneCycleLR

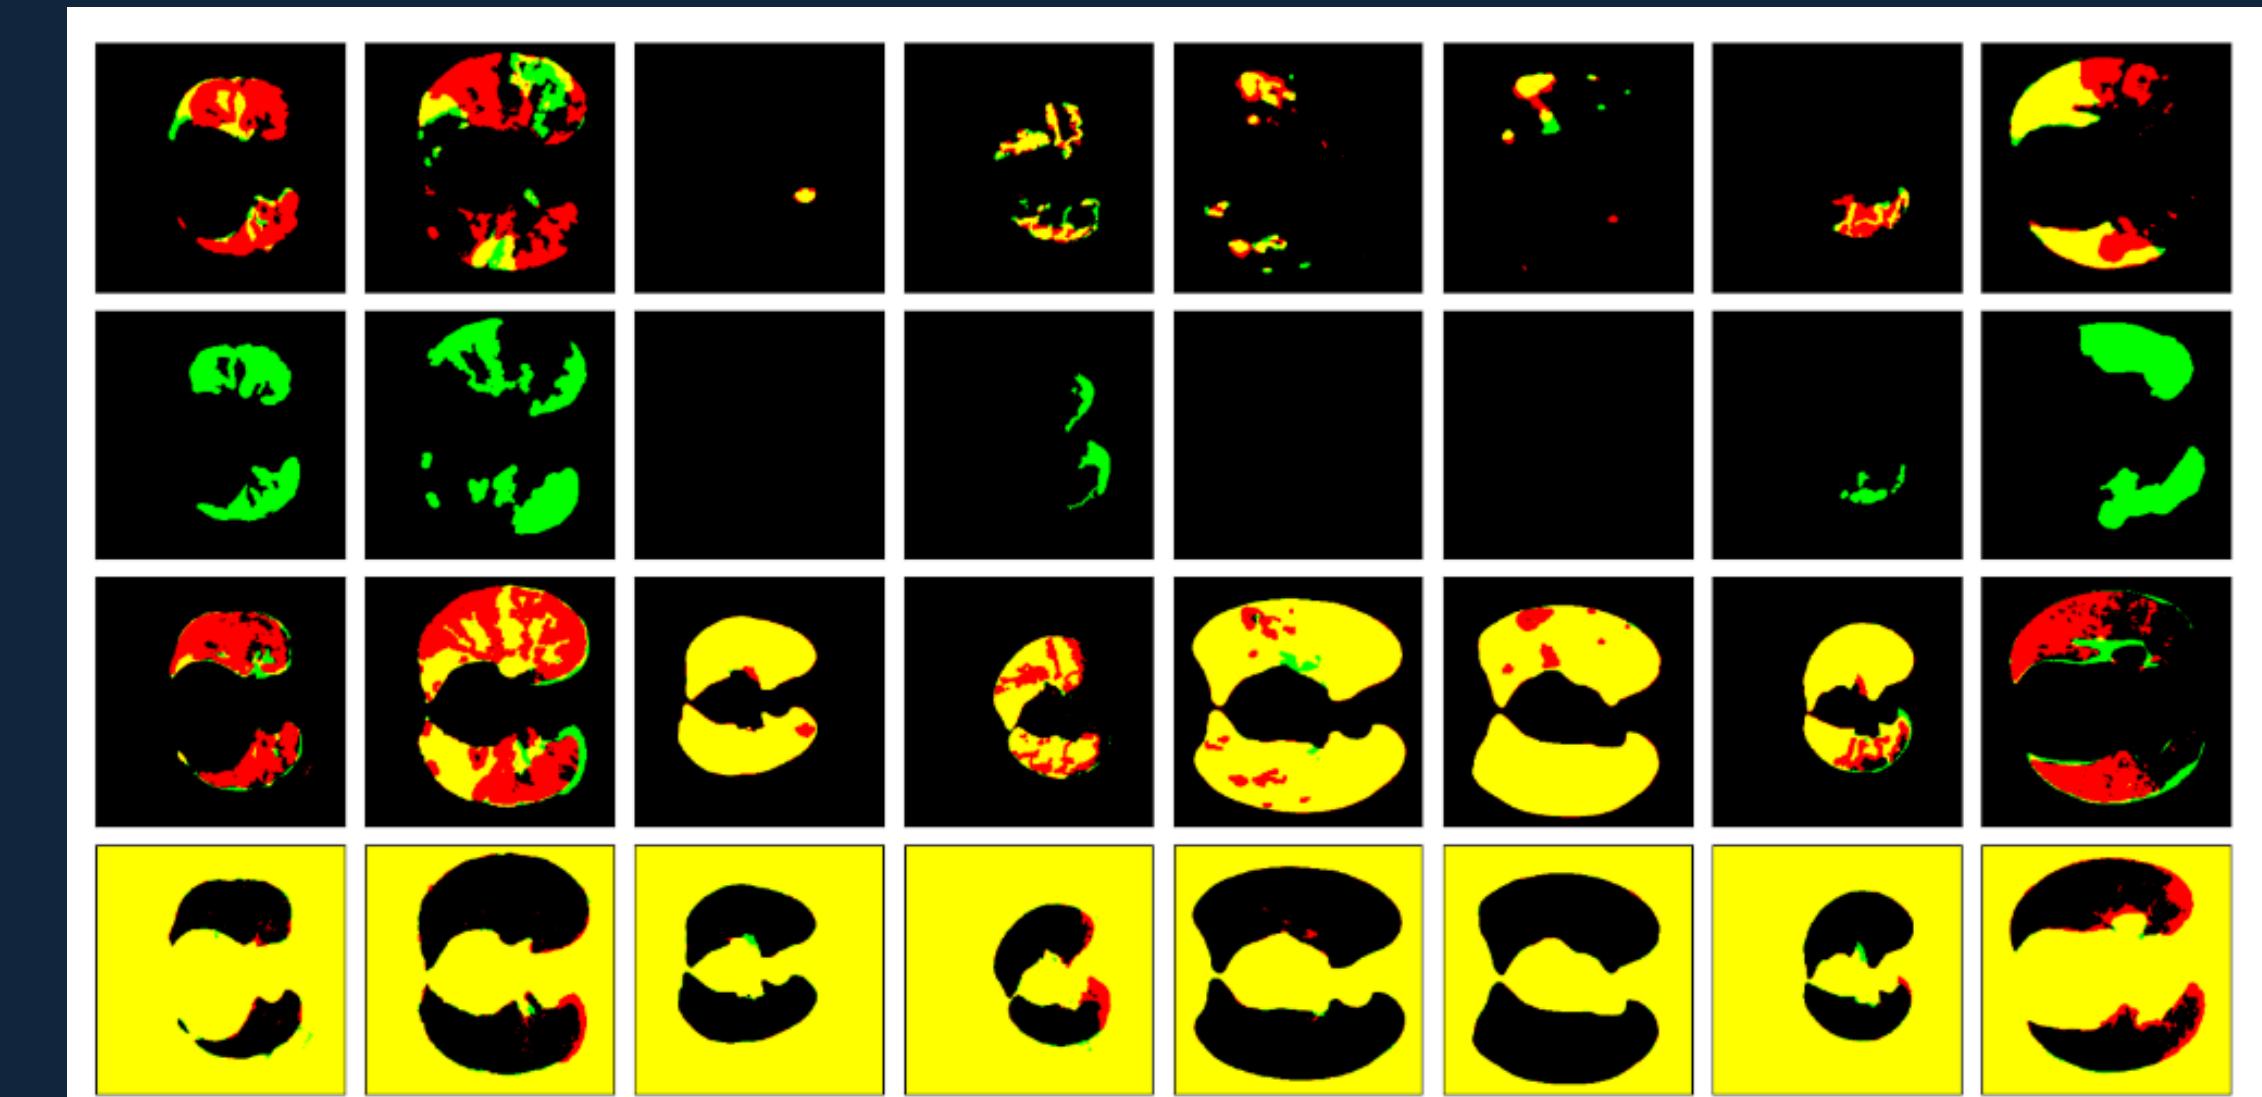
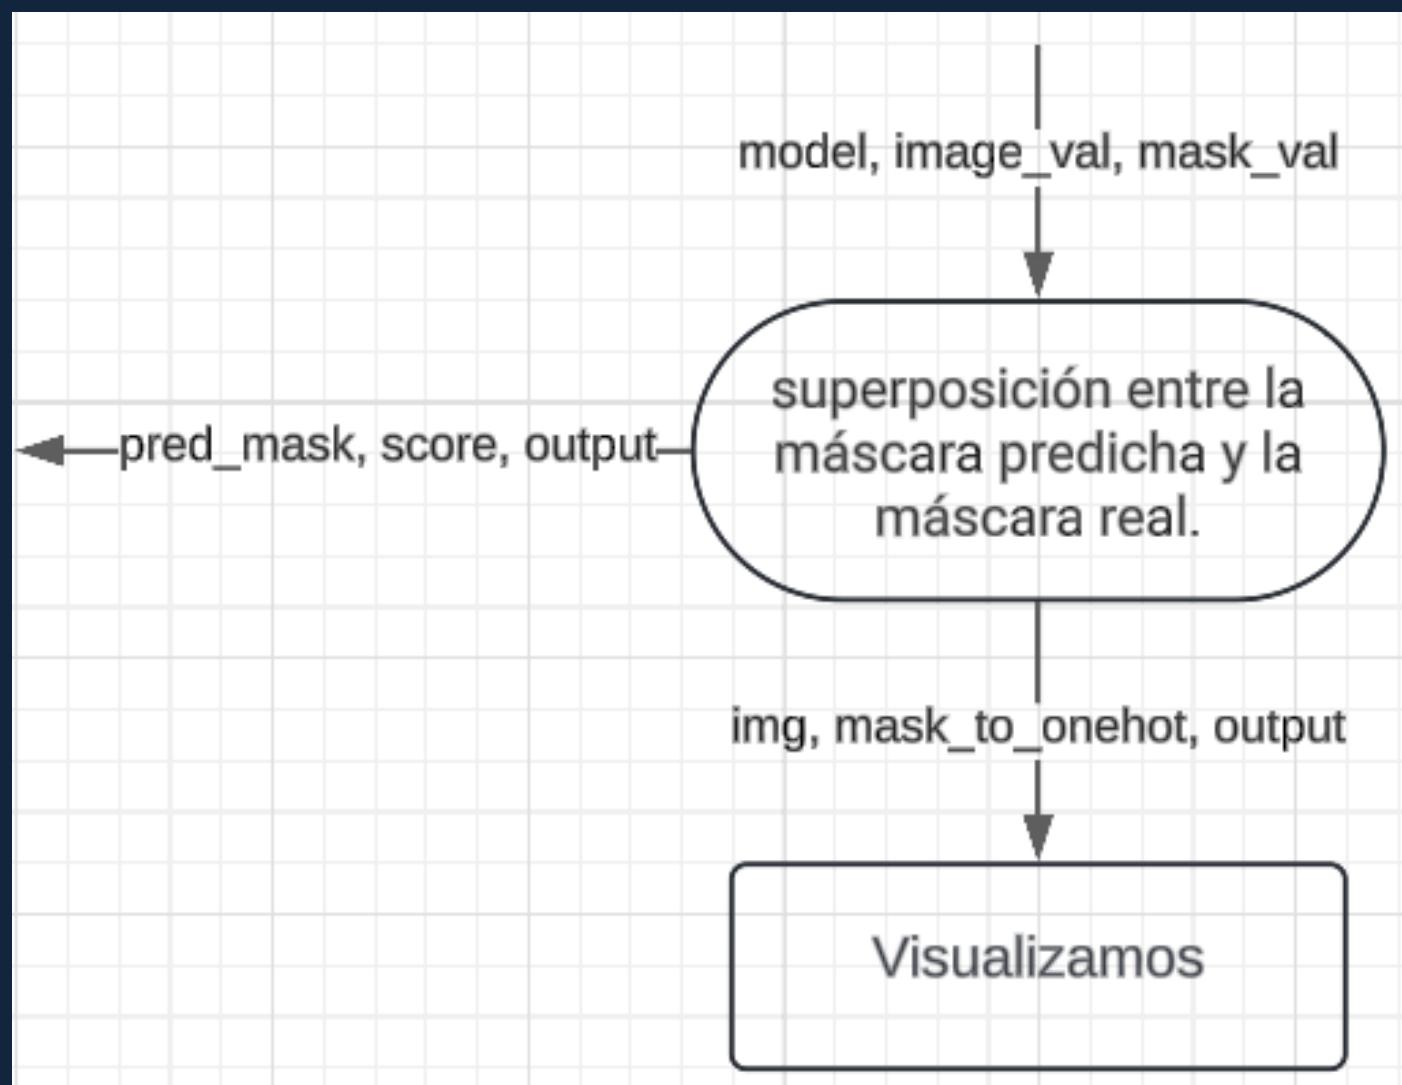
Resultados y Predicciones

Primera fila: muestra máscaras originales

Tercera y cuarta fila: Aquí es donde se encuentran las predicciones del modelo y las combinaciones de colores (rojo, verde, amarillo y negro), lo que permite observar qué tanto coinciden las predicciones del modelo con las máscaras originales.

Verde: Falso negativos, Rojo: Falso positivos, Amarillo: verdaderos positivos

Quinta: áreas no detectadas.



Posibles Mejoras



Hiperparámetros

Realizar diferentes ajustes de los parámetros para ver cuales se adaptarían mejor a nuestro modelo.



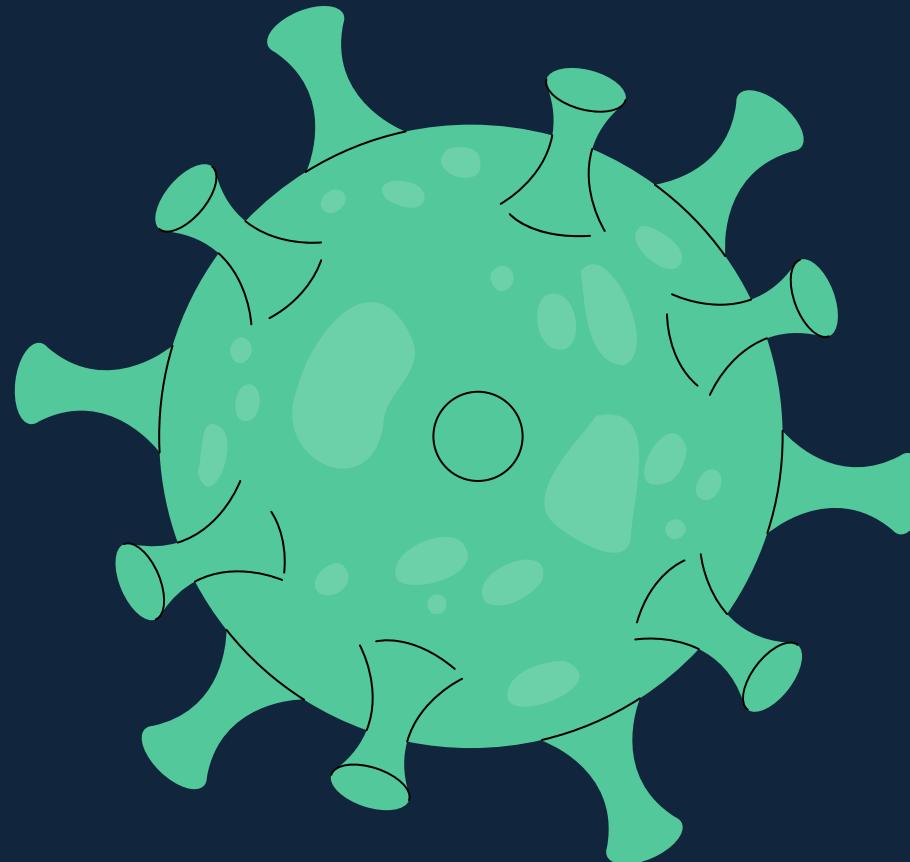
Búsqueda de hiperparámetros

Utilizar técnicas de búsqueda automática como Random Search o Grid Search para encontrar los mejores hiperparámetros del modelo.



Strategias para fitting

Trabajar con la topología de la red neuronal, hiperparámetros mientras se cuida que no haya underfitting u overfitting.



Referencias

Igor.Slinko. (2020). COVID-19 CT Images Segmentation . Kaggle.
<https://kaggle.com/competitions/covid-segmentation>

Maftouni M. (2021). PyTorch Baseline for Semantic Segmentation.
Kaggle. <https://www.kaggle.com/code/maedemaftouni/pytorch-baseline-for-semantic-segmentation>